

SnowFold GFP Design 2026

运用 ProteinMPNN + ESMFold 迭代设计 GFP 变体，从公开 PDB 结构出发，sort_score 从 0.80 提升至 **0.9477**。

项目简介

本项目参与 2026 合成生物 GFP 设计竞赛，目标是设计兼具高荧光亮度和优良热稳定性的 GFP 变体。核心管线采用 **ProteinMPNN** 进行序列生成/反向折叠，以 **ESMFold** 进行结构预测与质量评估（pTM / pLDDT / 生色团区域 pLDDT），通过多轮迭代筛选逐步优化排序分。

最终提交轮次（R25）的 Top-1 序列达到 sort_score = **0.9477**（pTM=0.9321, 全局 pLDDT=94.65, 生色团 pLDDT=96.96）。

完整设计链条（从零到 0.9477）

本项目从公开 PDB 结构出发，经历了以下完整流程：



▼ 关键修复: fixed position 1 (M)
R20: 修复后通过率从 8% → 62.8%
→ sort_score 0.9396
▼
R22: Phase 1+2 大规模 MPNN (5600 候选) + r=20 重算
→ sort_score 0.9430
▼
R24: R22 Top 6 父代 + GeoEvoBuilder 启发的跨度温度
→ sort_score 0.9447
▼
R25: R24 Top 6 父代 + 中低温精细优化 + r=20 重算
→ sort_score 0.9477 🐛

自主开发工具：gssh CLI

本项目全程使用了我们自主开发的 **gssh** 命令行工具——一个专为远程 GPU 服务器协作而设计的轻量 CLI，是本次实验高效迭代的核心基础设施。

为什么需要 gssh

本项目在 Windows 本地工作站 + 远程 A800 80GB 服务器之间进行多轮迭代。每轮实验需要：上传脚本到服务器 → 启动长时间 GPU 任务 → 实时监控日志 → 下载结果 JSON/CSV 回本地分析。传统 SSH/SCP 操作繁琐且无法管理后台任务，gssh 将这些操作整合为简洁命令。

核心功能

命令	功能	典型用法
<code>gssh run <session> "<cmd>"</code>	远程执行任务（自动后台化）	<code>gssh run 9ca7acb1b94c "python3 r25_server.py"</code>
<code>gssh cp <src> <dst></code>	双向文件传输	<code>gssh cp D:\r25.py session:/root/r25.py</code>
<code>gssh logs <task-id> -f</code>	实时查看任务日志	<code>gssh logs fff98ed2cf3b -f</code>
<code>gssh task stop <task-id></code>	停止远程任务	<code>gssh task stop 15e464541126</code>
<code>gssh --json exec <session> "<cmd>"</code>	一次性命令执行（JSON 输出）	<code>gssh --json exec 9ca7 "nvidia-smi"</code>

在本项目中的关键应用

- **R20-R27 全部远程任务**：脚本上传、GPU 任务启动、实时进度监控、结果下载均通过 gssh 完成
- **链式自动接力**：R25 通过 gssh 启动的 watcher 脚本，在 R24 完成后自动检测 GPU 空闲并启动 R25，实现无人值守的跨轮次自动化
- **并行管理**：同时管理本地 RTX 5080 和远程 A800 两个计算节点，按需调度

仓库说明

本仓库为 **SnowFold 竞赛核心仓库**，经过整理后仅保留从 R17 到 R27 的标准化 pipeline 脚本、最终结果和分析工具。

由于本项目跨越 27 轮迭代实验，原始工作目录中包含数百个脚本文件（含早期 ML 预测、多版本调试、中间筛选步骤、MPNN FASTA 输出、PDB 结构等），即使按轮次分类后每轮的相关文件仍然繁多且结构不一，不便于评审快速定位核心逻辑。

因此，我们将**标准化后的核心 pipeline 脚本**和**最终结果**提取到本仓库中，确保评审可以在数分钟内理解完整设计流程并复现关键实验。

完整的原始工作记录（含 R1-R16 早期探索阶段的全部脚本、中间文件和数据）可在原始仓库中查阅：

- **原始仓库:** 2026Protein Design 根目录（含 work/round2 ~ work/round16 全部脚本和数据，共计 500+ 文件）

最终成绩

指标	值
sort_score (Top-1)	0.9477
pTM	0.9321
全局 pLDDT	94.65
生色团 pLDDT (残基 58-72)	96.96
提交轮次	R25
提交序列数	6

排序分公式

sort_score = (pTM × 0.40) + (全局pLDDT / 100 × 0.30) + (生色团pLDDT / 100 × 0.30)

技术栈

- **语言:** Python 3.10+
- **深度学习:** PyTorch >= 2.0, CUDA 12+
- **序列生成:** ProteinMPNN (v_48_020)
- **结构预测:** ESMFold (facebook/esmfold_v1) via HuggingFace Transformers
- **数据分析:** NumPy, SciPy, Matplotlib

环境配置要求

项目	要求
----	----

Python	3.10+
CUDA	12.0+
GPU 显存	16GB+ (ESMFold 推理最低要求)
操作系统	Linux (推荐) / Windows
磁盘空间	10GB+ (模型权重 + 中间结果)

安装依赖

```
# 创建虚拟环境
python -m venv venv
source venv/bin/activate # Linux
# venv\Scripts\activate # Windows

# 安装依赖
pip install -r requirements.txt

# 安装 ProteinMPNN (需单独克隆)
git clone https://github.com/dauparas/ProteinMPNN.git
cd ProteinMPNN
pip install -e .
```

模型依赖

模型	版本/路径	用途
ESMFold	facebook/esmfold_v1 (HuggingFace)	结构预测, 输出 pTM / pLDDT
ProteinMPNN	v_48_020 (权重文件)	序列生成 / 反向折叠

ESMFold 首次运行时会自动从 HuggingFace Hub 下载模型权重 (约 2.5GB) 。

推理代码运行方式

以下是从 R19 到 R25 的完整迭代流程。每轮的核心逻辑为：**加载上一轮 Top 序列** → **ProteinMPNN 采样生成** → **ESMFold 结构预测** → **计算排序分** → **保留 Top 候选作为下一轮父代**。

Step 1: R19 — 基准轮

```
cd pipeline
python r19_pipeline.py
```

- 父代: R18 Top6
- 温度: 5 档

- 候选数: 200
- Fixed positions: [65, 66, 67, 96, 222]
- ESMFold recycles: 8
- 结果: sort_score = 0.9321

Step 2: R20 — Fixed position 1 (M) 修复

```
python r20_pipeline.py # 生成 + 初筛
python r20_finalize.py # 终筛 + 导出
```

- 父代: R19 Top6
- 温度: 4 档
- 候选数: 2000
- Fixed positions: [1, 65, 66, 67, 96, 222] (新增 position 1 固定为 M)
- 结果: sort_score = 0.9396 (+0.0075)

Step 3: R22 — Phase 2 大规模 MPNN

```
python r22_pipeline.py # 主管线
python r22_long.py # 长时间批量任务
```

- 父代: R20 Top6
- 温度: 4 档
- 候选数: 5600
- ESMFold recycles: 8 + 20 (高精度重算)
- 结果: sort_score = 0.9430 (+0.0034)

Step 4: R24 — 跨度温度探索

```
# 服务器端运行
python r24_server.py
```

- 父代: R22 Top6
- 温度: 5 档跨度
- 候选数: 6000
- 结果: sort_score = 0.9447 (+0.0017)

Step 5: R25 — 中低温精调 (最终提交轮)

```
# 服务器端运行
python r25_server.py

# 可选: 监控脚本
bash r25_watcher.sh
```

- 父代: R24 Top6

- 温度: 5 档中低温 [0.05 - 0.3]
- 候选数: 6000
- ESMFold recycles: 8 + 20 (高精度重算)
- 结果: **sort_score = 0.9477** (+0.0030) 📄

后续探索轮（未提交）

- **R26** (r26_local.py): 本地小规模验证, sort_score = 0.9449
- **R27** (r27_server.py, r27_diverge.py): 5 方向多样性探索, sort_score = 0.9480

分析工具

```
cd analysis
python check_compliance.py # 格式合规性检查
python analyze_r22.py      # R22 结果分析
python analyze_r23.py      # R23 结果分析
python analyze_r26.py      # R26 结果分析
python r24_check.py        # R24 结果校验
```

目录结构

```
SnowFold-GFP-2026/
├── README.md          # 本文件
├── requirements.txt    # Python 依赖
├── .gitignore
├── submission/
│   └── submission_r25.csv # 最终提交的 6 条序列
├── pipeline/          # 各轮生成管线脚本
│   ├── r19_pipeline.py
│   ├── r20_pipeline.py
│   ├── r20_finalize.py
│   ├── r22_long.py
│   ├── r22_pipeline.py
│   ├── r23_server.py
│   ├── r23_local.py
│   ├── r24_server.py
│   ├── r25_server.py
│   ├── r25_watcher.sh
│   ├── r26_local.py
│   ├── r27_server.py
│   ├── r27_diverge.py
│   ├── r28_local_mutscan.py
│   └── r28_watcher.ps1
├── analysis/          # 分析与校验脚本
│   ├── check_compliance.py
│   ├── analyze_r22.py
│   ├── analyze_r23.py
│   ├── analyze_r26.py
│   └── r24_check.py
├── results/           # 各轮 Top6 候选结果
└── round19/
```

```
| |— round20/
| |— round22/
| |  |— final_6_r22.json
| |— round23/
| |  |— final_6_r23.json
| |— round24/
| |— round25/
| |  |— final_6_r25.json
| |— round26/
| |  |— final_6_r26.json
| |— round27/
| |  |— final_6_r27.json
|— docs/          # 设计文档与报告
|  |— R22-R27_final_report.md
|  |— round24-27_report.md
|  |— round25_report.md
|  |— r24_briefing.md
```

各轮实验条件汇总

轮次	父代	温度策略	候选数	Fixed Positions	Recycles	Top1 sort_score
R19	R18 Top6	5 档	200	[65,66,67,96,222]	8	0.9321
R20	R19 Top6	4 档	2000	[1,65,66,67,96,222]	8	0.9396
R22	R20 Top6	4 档	5600	[1,65,66,67,96,222]	8+20	0.9430
R23	R20 Top3	5 档高温	2250	[1,65,66,67,96,222]	8	0.9419
R24	R22 Top6	5 档跨度	6000	[1,65,66,67,96,222]	8	0.9447
R25	R24 Top6	5 档中低温	6000	[1,65,66,67,96,222]	8+20	0.9477
R26	R24 Top2	3 档	600	[1,65,66,67,96,222]	8	0.9449
R27	R25 Top2	5 方向	680	多种	8	0.9480

关键发现

- Fixed position 1 (M)** 是最关键修复 (R19→R20: +0.0075)
- 父代质量决定上限** — 每轮用上一轮 Top 6 作父代
- 中低温 [0.05-0.3]** 是最佳温度范围
- 超高温 [1.0+]** 完全无效 (通过率仅 1-2%)
- ESMFold r=8 已收敛** (r=20 差异 <0.001)
- MPNN+ESMFold 天花板约 0.95** (当前 0.948, 剩余约 0.002)

Agent 逻辑树说明

本项目使用 **Trae AI Agent** 辅助设计与迭代。Agent 的核心逻辑树如下：



Agent 关键执行日志

以下是 Agent 在各轮实验中的关键决策节点和执行记录，展示了从问题发现到策略调整的完整推理链。

R17→R18: ESMFold 校准与基线建立

- **问题发现:** Agent 注意到本地 ESMFold 的 pLDDT 输出与 HuggingFace 官方实现存在 0-1 vs 0-100 的尺度差异，导致早期评分偏低
- **自动修复:** Agent 在代码中加入 `plddt.mean()` 标准化，统一到 0-1 比例
- **策略调整:** 将 recycles 从 4 提高到 8，发现 sort_score 稳定提升 +0.002

R18→R19: 大规模搜索空间探索

- **决策:** Agent 分析 R18 仅用 4 父代 × 3 温度 × 50 候选 = 900 候选，搜索空间不足
- **执行:** 扩展到 9 父代 (R18 Top 6 + 3 个 WT 参考序列) × 5 温度 × 150 候选 = 6750 候选
- **结果:** sort_score 0.908 → 0.9321 (+0.024)，验证了"更大搜索空间 → 更高分数"假设

R19→R20: 关键 Bug 发现与修复 (最大突破)

- **异常检测:** Agent 在 R19 结果分析中发现 97% 的候选序列**不以 M 开头**, 违反竞赛规则
- **根因定位:** Agent 追踪到 ProteinMPNN 的 `fixed_positions` 参数缺少 position 1, MPNN 未固定起始甲硫氨酸
- **自动修复:** 将 `FIXED = [65, 66, 67, 96, 222]` 改为 `FIXED = [1, 65, 66, 67, 96, 222]`
- **效果:** 通过率从 ~8% 跃升至 62.8%, `sort_score` 0.9321 → 0.9396 (**+0.0075, 项目最大单轮提升**)
- **日志摘录:** "97% 候选不以 M 开头 → 违反规则 → FIXED 缺 position 1 → 修复 → 通过率 8%→62.8%"

R20→R22: Phase 1+2 流水线设计

- **策略推理:** Agent 分析 R20 Top 6 分布后发现分数集中在 0.939 附近, 单轮 MPNN 难以突破
- **方案设计:** Agent 设计了双阶段流水线:
 - Phase 1: R20 finalize (2000 候选, 确认父代质量)
 - Phase 2: 大规模 MPNN (3600 候选, 6 父代 × 4 温度 × 150)
 - Phase 3: Top 20 用 `r=20` 高精度重算
- **验证:** `r=8` vs `r=20` 差异全部 < 0.001, 确认 `r=8` 结果可信
- **结果:** `sort_score` 0.9396 → 0.9430 (+0.0034)

R22→R24: 跨轮父代链 + 文献调研

- **文献调研:** Agent 搜索到 GeoEvoBuilder (PNAS 2025.10), 专门为 GFP 设计的 zero-shot 框架, 同时优化活性和热稳定性
- **代码下载尝试:** GitHub 下载失败 (网络限制), Agent 决定用现有工具模拟其核心思路
- **策略调整:** 用 R22 Top 6 (0.9430) 作父代 + 跨度温度 [0.05-0.8] (比 R22 更宽)
- **结果:** `sort_score` 0.9430 → 0.9447 (+0.0017), `pTM` 0.9276 → 0.9305 创纪录

R24→R25: 中低温聚焦 + 自动接力 (最终突破)

- **温度分析:** Agent 统计 R24 各温度段产出发现 `T=0.05-0.2` 贡献了 80% 的高分候选
- **策略聚焦:** 将温度范围从 [0.05-0.8] 收窄到 [0.05-0.6], 去掉高温段
- **自动化:** Agent 编写 `watcher` 脚本, 在 R24 完成后自动检测 GPU 空闲并启动 R25, 实现无人值守
- **结果:** `sort_score` 0.9447 → **0.9477** (+0.0030), `chromo pLDDT` 突破 0.970
- **日志摘录:** "R24 done + GPU free + time OK → Launching R25!"

R25→R27: 边界探测与多样性探索

- **边界分析:** Agent 计算各分项剩余空间 (`pTM` 6.8%, `pLDDT` 5.3%, `chromo` 3.0%), 判断 MPNN+ESMFold 天花板约 0.95
- **5 方向探索:** Agent 设计了 5 个方向同时测试:
 - A 极低温 [0.01, 0.05] → `top`=0.9480 (微幅突破)
 - B 超高温 [1.0, 1.5] → 通过率 1%, 结构破坏
 - C 极少固定 [66,67,222] → MPNN 几乎复制父代
 - D 超宽固定 [1,2,65,66,67,96,203,222] → `top`=0.9458
 - E 全谱温度 → 高温段生成失败
- **结论:** Agent 判定已极度逼近局部最优, 进一步突破需要新方法 (AlphaFold2/ESM3/RFdiffusion3)

数据库与可视化系统

- **数据整合:** Agent 自动将 27 轮实验的 238,691 条去重序列、402,650 条标记记录导入 SQLite 数据库

- **可视化:** Agent 搭建了三栏交互式网站 (FastAPI + React + Cytoscape + Plotly) , 支持序列检索、谱系网络、图表联动
- **R 图表:** Agent 编写 R 脚本生成高质量图表 (分数趋势、pTM×chromo 散点、Top30 热图、序列 identity 矩阵)
- **Docker 部署:** 全部服务容器化, 避免端口冲突

License

MIT License

Copyright (c) 2026 SnowFold